

Laporan Tugas Mingguan 1 Data Mining

Web Scrape dan EDA

Nama: Dean Arkeanu Andharu

NRP: 5054231020

Mata Kuliah: Data Mining

Laporan ini merupakan laporan hasil untuk tugas EDA dan Web Scrape dari dua halaman Wikipedia, yaitu daftar planet minor, data 1-1000 untuk page 1, dan data 1001-2000 untuk page 2. Pengambilan data dilakukan dengan BeautifulSoup dan Library Python. Setiap halaman yang diambil memiliki 10 tabel berisi 100 objek, seluruh tabel kemudian digabungkan menggunakan library pandas menjadi dataset mentah berukuran 2000 baris dan 9 kolom dan disimpan sebagai `minor_planets_raw.csv` sebelum selanjutnya dilakukan proses pembersihan.

1. Deskripsi Dataset

Dataset mentah terdiri atas sembilan atribut. Sebagian besar atribut bersifat nominal; `Discovery_Date` merupakan atribut temporal, `Diameter` merupakan numerik kontinu. Tidak terdapat atribut ordinal yang jelas. Setelah cleaning, dibuat atribut turunan `Planet_Number`, `Planet_Name`, `Discovery_Year`, `Diameter_km`, dan `Category_Analysis` sehingga dataset akhir berukuran 2.000 baris $\times$ 14 kolom.

Atribut	Tipe	Keterangan
Permanent	Nominal/identifier	Nomor dan nama permanen
Provisional	Nominal	Kode penamaan sementara
Named After	Nominal	Asal/nama penamaan
Discovery Date	Temporal	Tanggal penemuan
Discovery Site	Nominal	Lokasi penemuan
Discoverer	Nominal	Penemu/instansi
Category	Nominal	Kategori minor planet
Diameter	Numerik kontinu	Diameter objek
Reference	Nominal	Sumber referensi

Tabel 1.1 Deskripsi Dataset

2. Statistik Deskriptif

Analisis numerik difokuskan pada `Discovery_Year` dan `Diameter_km`. `Planet_Number` tidak digunakan sebagai variabel statistik utama karena berfungsi sebagai identifier. Hasil statistik menunjukkan bahwa tahun penemuan memiliki rata-rata 1918,62 dan median 1922,5. `Diameter` memiliki rata-rata 46,83 km, tetapi median hanya 31 km; selisih mean–median dan standar deviasi 50,87 km menunjukkan distribusi diameter yang tidak simetris dan dipengaruhi objek berukuran sangat besar.

Atribut	Mean	Median	Modus	Std. Dev.	Min	Maks
Discovery_Year	1918,62	1922,5	1938	27,86	1801	1975
Diameter_km	46,83	31,0	12,0	50,87	0,5	939,0

Tabel 2 Data Statistik

3. Penanganan Data

Pemeriksaan awal dengan `isnull()` menghasilkan nol missing value karena Wikipedia menggunakan placeholder teks. Pemeriksaan simbol menemukan “—” sebanyak 331 kali pada Provisional dan “.” sebanyak 1.304 kali pada Category. Placeholder tersebut dikonversi menjadi NaN sehingga missing value sebenarnya menjadi 331 (16,55%) pada Provisional dan 1.304 (65,20%) pada Category; atribut lain tidak memiliki nilai hilang. Missing value tidak dihapus secara massal karena baris terkait masih memiliki informasi penting pada atribut lain.

Cleaning juga memisahkan Permanent menjadi Planet_Number dan Planet_Name, mengubah Discovery_Date menjadi datetime, membentuk Discovery_Year, serta mengonversi Diameter ke kilometer. Satu nilai, 1915 Quetzálcoatl, ditulis 500 m (1,600 ft) sehingga awalnya gagal dikonversi; fungsi konversi diperbaiki agar menangani km dan m, menghasilkan 0,5 km dan akhirnya tidak ada diameter yang gagal dikonversi. Validasi akhir menunjukkan 2.000 baris, 14 kolom, dan 0 baris duplikat.


4. Deteksi Outlier

Outlier dideteksi dengan metode Interquartile Range (IQR). Pada Diameter_km, $Q1 = 15$ km dan $Q3 = 63$ km sehingga $IQR = 48$ km, batas atas = 135 km, dan terdapat 106 outlier (5,30%). Objek terbesar antara lain Ceres 939 km, Vesta 523 km, Pallas 513 km, Hygiea 407 km, dan Interamnia 306 km. Pada Discovery_Year, $Q1 = 1902$, $Q3 = 1936$, $IQR = 34$, batas bawah = 1851 dan batas atas = 1987; terdapat 13 outlier (0,65%), yaitu penemuan awal 1801–1850. Outlier dipertahankan karena merepresentasikan nilai nyata, bukan kesalahan input.

Atribut	Batas bawah	Batas atas	Outlier	Persentase
Diameter_km	-57,0	135,0	106	5,30%
Discovery_Year	1851,0	1987,0	13	0,65%

Tabel 3 Deteksi Outlier

5. Visualisasi dan Interpretasi Data



Gambar 1 Visualisasi Data

Histogram diameter memperlihatkan distribusi sangat miring ke kanan: sebagian besar objek berada pada diameter kecil, sedangkan sejumlah kecil objek berdiameter besar membentuk ekor panjang dan sesuai dengan outlier IQR. Sementara itu, Scatter plot dan heatmap menunjukkan korelasi Discovery_Year–Diameter_km sebesar $-0,602683$ ($\approx -0,60$), yaitu hubungan negatif sedang: pada dataset ini, objek yang ditemukan pada tahun yang lebih baru cenderung memiliki diameter lebih kecil. Hubungan ini bersifat asosiasi dan tidak menyatakan sebab-akibat.